

Otimização de Rotas (SupplyChain Optimazer)

Luis Henrique Turra Ramos

14 de novembro de 2025

Objetivo: O objetivo principal dessa análise é avaliar a eficiência de algoritmos de Reinforcement Learning na otimização de rotas logísticas em São Paulo, comparando Q-Learning e Deep Q-Network (DQN) para minimizar custos de transporte e atendimento de demandas.

Introdução: A análise busca alcançar a criação e avaliação de um sistema de otimização de rotas logísticas que utiliza inteligência artificial para reduzir custos operacionais em cenários urbanos como São Paulo. Ao integrar dados geográficos e de demanda, o projeto pretende demonstrar como algoritmos de aprendizado por reforço podem melhorar a eficiência de entregas, comparando uma abordagem tabular (Q-Learning) com uma neural profunda (DQN) para identificar a melhor estratégia em termos de escalabilidade e performance.

Metodologia:

Fontes de Dados: Dados forma gerados manualmente, contendo coordenadas geográficas (latitude e longitude) e níveis de demanda para pontos em São Paulo, simulando locais de entrega reais. Esses dados foram processados para representar um depósito central e clientes distribuídos na cidade.

Técnicas de Análise: As técnicas de análise incluíram o desenvolvimento de ambientes de simulação com Reinforcement Learning em Python, empregando Q-Learning para criação de tabelas de valores e DQN com redes neurais em PyTorch. O treinamento ocorreu em ambientes locais e no Google Colab para DQN e avaliação baseada em métricas de custo total, número de passos e entregas completas. Mapa do estado de São Paulo feito em folium e visual dashboard feito em gradio.

Limitações: dependência de dados simulados, que podem não capturar variações reais como tráfego ou condições climáticas, além de restrições computacionais no Q-Learning para conjuntos maiores de dados.

Resultados: A implementação do Q-Learning resultou em uma rota otimizada para 10 clientes, com custo total de R\$ 1.975, completando 10 entregas em 12 passos, demonstrando eficiência em ambientes de baixa complexidade com convergência rápida. Já o DQN escalou para 19 clientes (limitado pelo tamanho do CSV), alcançando custo de R\$ 2.368 para 19 entregas em 24 passos, mostrando capacidade de lidar com estados mais complexos sem perda significativa de performance. Em termos de comparação, o Q-Learning apresentou uma média de custo por entrega de R\$ 197, enquanto o DQN manteve R\$ 124 por entrega em um conjunto com quase o dobro de entregas, destacando a robustez do modelo neural.

Discussão: Os resultados indicam que o Q-Learning é adequado para otimização em escalas pequenas, onde a simplicidade da tabela de valores permite treinamento rápido e soluções estáveis, refletindo uma redução efetiva de custos em cenários limitados como entregas locais. No contexto do objetivo, isso significa que para operações com poucos pontos, o algoritmo oferece economia imediata sem necessidade de recursos computacionais avançados. Por outro lado, o DQN revela superioridade em escalabilidade, mantendo custos proporcionais mesmo com mais clientes, o que interpreta os dados como uma oportunidade para aplicações reais em logística urbana, onde o número de entregas varia diariamente, reduzindo ineficiências como rotas redundantes.

Conclusões: Em resposta direta ao objetivo inicial, a análise confirma que algoritmos de Reinforcement Learning, especialmente o DQN, alcançam otimização efetiva de rotas logísticas em São Paulo, provando a viabilidade de IA para eficiência operacional sem comprometer a performance.